

Evaluación Parcial N° 2

Procesos básicos con Big Data

Estudiante

Sigla	Nombre Asignatura	Tiempo Asignado	% Ponderación
AVY1101	Big Data	4h	40%

1. Situación Evaluativa:

Ejecución práctica

x	Entrega de encargo
---	--------------------

x	Presentación
---	--------------

2. Instrucciones

Descripción general de la evaluación

El/la estudiante debe construir los procesos de (1) ingesta, (2) transformación y limpieza, (3) carga en una base de datos en el ambiente Big Data, para el conjunto de datos del caso en modalidad batch. Los procesos involucrados deben considerar el manejo de errores correspondientes, para evitar “caídas” en la ejecución de estos.

- El propósito de esta evaluación es evaluar los siguientes Indicadores de Logro:
 - *IL 2.1 Construye procesos de carga de datos Batch en diferentes formatos y desde diversas fuentes.*
 - *IL 2.2 Almacena la información para realizar procesos de limpieza y transformación de datos.*

- *IL 2.3 Construye procesos de limpieza, transformación y almacenamiento de grandes volúmenes de datos.*
- *IL 2.4 Construye gráficos que permitan mostrar de manera simple los insight relevantes encontrados en los datos.*

- Esta evaluación consiste en una entrega de encargo con presentación y tiene un **40%** de ponderación sobre la nota final de las evaluaciones parciales.
- **El Tiempo** asignado para el desarrollo del encargo es de **4 semanas** (entrega de instrucciones la semana 8), entregándose el informe el mismo día de la presentación, **la semana 12**. Para la presentación o defensa cuentan **con 10 (minutos)** y se realiza en **parejas** en **Taller de alto computo**.
- La **distribución de los porcentajes de las situaciones evaluativas que componen esta evaluación** es la siguiente:

Evaluación	Porcentaje dentro de la asignatura	Tipo de situación evaluativa	Distribución de porcentajes
Evaluación Parcial N° 2	40%	A Encargo	30%
		B Presentación	70%

Instrucciones Específicas**Dimensión encargo:**

Deberán realizar la gestión de grandes volúmenes de Datos, mediante la carga histórica de todos los archivos disponibles, la cual permita a los usuarios responder diversas preguntas de negocio relacionadas con el caso a resolver.

Paso 1: Realizar las conexiones con la fuente de origen de datos (estas pueden ser bases de datos, archivos que deben descargar desde internet, etc.).

Paso 2: Descargar y/o generar los archivos al dataLake con los servicios para compartir archivos con clientes o proveedores. Generar repositorios de datos que almacenan grandes cantidades de datos, realizando un DataLake con BigQuery o con Cloud Storage para compartir datos con clientes o proveedores.

Paso 3: Construir los procesos de limpieza, transformación y carga al modelo de datos final.

Paso 4: Construir los reportes y/o visualizaciones correspondientes, con la finalidad de crear dashboard con 4 gráficos representativos y predictivos de la información procesada en el proceso desde los orígenes de datos.

Para lo anterior, deberá realizar lo siguiente:

- Construir procesos de carga en data Lake, considerando disponibilidad de la información desde de la fuente
- Construir procesos de transformación, limpieza de datos Batch.
- Construir procesos orquestados considerando disponibilidad de información y dependencias de grandes volúmenes de datos en formato Batch.

Para cada uno de estos pasos, debe considerar (si aplica) lo siguiente:

- Control de errores: todos los procesos pueden tener puntos de fallo, de acuerdo con lo identificado en la etapa de diseño, debe implementar los controles de errores correspondientes.

- Control de duplicidad de archivos: Los DataLake contienen múltiples archivos, debe considerar que los procesos se pueden ejecutar múltiples veces, por tanto, sus procesos deben determinar qué hacer si un fichero y/o datos ya existen (tome la decisión de acuerdo con lo visto durante el semestre).
- Registro de actividad: Como se señaló anteriormente, los procesos se podrían ejecutar varias veces, debe incorporar el control de ejecución (ej.: ¿si el proceso ya se ejecutó lo debo volver a ejecutar, lo debo bloquear o debo pedir autorización para volver a ejecutar?).
- Validación de Datos y Procesos: Según corresponda, debe considerar en su construcción la validación de los procesos y la validación de los datos a trabajar, incluyendo procesos de transformación, manteniendo la trazabilidad de los datos desde el origen. Tenga en cuenta que al ser datos Batch, los procesos deben permitir reprocesar datos históricos en alguna fecha en particular.

Dimensión presentación:

- Para la presentación, deberán simular una entrega gerencial, evaluada individualmente.
- Presentar la construcción del proceso de carga de datos (ingesta) en diferentes formatos y de diversas fuentes, ya sea batch o streaming.
- Presentar la construcción de procesos con el fin de realizar limpieza, transformación y almacenamiento de grandes volúmenes de datos formato Batch.
- Presenta los resultados siguiendo una estructura lógica, considerando la información del informe.
- Deberá utilizar un lenguaje técnico propio de la disciplina, además de justificar y responder preguntas sobre cualquier aspecto trabajado.

Se recomienda revisar la rúbrica de la evaluación para conocer detalladamente los aspectos a evaluar.

Aunque esta evaluación se desarrolla en duplas, la calificación es de carácter individual y responde al desempeño particular de cada integrante.

Aspectos Formales○ **Producto/informe:**

- Subir a plataforma AVA
- Formato .pdf con un máximo de 10 páginas, en fuentes Arial o Calibri, tamaño 10 a 12.
- Portada con detalle de sección, nombre y rut de los integrantes.
- Introducción
- Índice.
- Desarrollo: Todos los apartados del encargo.
- Los trabajos entregados fuera de plazo serán calificados con nota 1.0.

○ **Presentación:**

- Tiempo máximo de presentación 10 minutos, 5 minutos para responder preguntas.
- Máximo 10 láminas, debe considerar los aspectos más importantes y que estas son solo apoyo. Se recomienda la utilización de plantillas interactivas, en las cuales se priorice la organización de información en diagramas, flujo de procesos, tablas consolidadas.
- Las diapositivas o láminas deben ser formales. Se adjunta formato PowerPoint, se espera correcta ortografía, colores adecuados y diapositivas sintéticas, etc.
- Distribución de tiempos y trabajo debe ser equivalente entre los integrantes del equipo.
- Las preguntas pueden ser realizada a cualquier integrante del equipo

Anexos

En el caso del informe, puede agregar como anexo o punto final los recursos que considere necesarios.

3. Pauta de Evaluación

Tipo de Pauta: Rúbrica

Categoría	% logro	Descripción niveles de logro
Muy buen desempeño	100%	Demuestra un desempeño destacado, evidenciando el logro de todos los aspectos evaluados en el indicador.
Buen desempeño	80%	Demuestra un alto desempeño del indicador, presentando pequeñas omisiones, dificultades y/o errores.
Desempeño aceptable	60%	Demuestra un desempeño competente, evidenciando el logro de los elementos básicos del indicador, pero con omisiones, dificultades o errores.
Desempeño incipiente	30%	Presenta importantes omisiones, dificultades o errores en el desempeño, que no permiten evidenciar los elementos básicos del logro del indicador, por lo que no puede ser considerado competente.
Desempeño no logrado	0%	Presenta ausencia o incorrecto desempeño.

Indicador de Evaluación	Categorías de Respuesta					Ponderación Indicador de Evaluación
	Muy buen desempeño 100%	Buen desempeño 80%	Desempeño aceptable 60%	Desempeño incipiente 30%	Desempeño no logrado 0%	
Dimensión encargo						
1. Construye proceso de carga de datos Batch en diferentes formatos y de diversas fuentes.	Construye procesos de carga de datos a partir de: - uso de diversos formatos. - uso de diferentes fuentes de datos - proceso de ingesta robusto - uso de herramientas como ETL - sistemas de colas, servicios de integración en la nube - desarrollo de código propio	Construye procesos de carga de datos considerando entre cinco o seis aspectos : Los cuales se identifican claramente en su proyecto , asegurando el éxito de este.	Construye procesos de carga de datos considerando entre tres o cuatro : Los cuales se identifican claramente en su proyecto , asegurando el éxito de este.	Construye procesos de carga de datos considerando entre uno o dos : Los cuales se identifican claramente en su proyecto , asegurando el éxito de este.	No considera los aspectos mencionados o no se identifica ninguno claramente en su proyecto.	5%

	-gestión de errores. Los cuales se identifican claramente en su proyecto , asegurando el éxito de este.					
2. Almacena la información para realizar procesos de limpieza y transformación de datos.	Almacena la información en su totalidad para realizar procesos de limpieza y transformación de datos.	Almacena el 80% de la información para realizar procesos de limpieza y transformación de datos.	Almacena 60% y de la información para realizar procesos de limpieza y transformación de datos.	Almacena el 30% de la información para realizar procesos de limpieza y transformación de datos.	No almacena información o es insuficiente.	5%
3. Construye procesos de limpieza, transformación y almacenamiento de grandes volúmenes de datos.	Construye procesos de limpieza y transformación que consideren cuatro aspectos como: normalización, agregación, enriquecimiento, validación, limpieza y de duplicación. Los cuales aseguran una carga exitosa y completa de los datos desde las fuentes de origen.	Construye procesos de limpieza y transformación que consideren solo tres de los aspectos mencionados . Los cuales aseguran una carga exitosa y completa de los datos desde las fuentes de origen.	Construye procesos de limpieza y transformación que consideren solo dos de los aspectos mencionados . Los cuales aseguran una carga exitosa y completa de los datos desde las fuentes de origen.	Construye procesos de limpieza y transformación que consideren solo uno de los aspectos mencionados . El cual asegura una carga exitosa y completa de los datos desde las fuentes de origen.	No construye estos procesos.	5%
4. Construye gráficos que permitan mostrar de manera simple los insight relevantes encontrados en los datos.	Construye completamente 4 gráficos (dimensiones) que permitan mostrar de manera simple los insight relevantes encontrados en los datos.	Construye completamente 3 gráficos (dimensiones) que permitan mostrar de manera simple los insight relevantes encontrados en los datos.	Construye completamente 2 gráficos (dimensiones) que permitan mostrar de manera simple los insight relevantes encontrados en los datos.	Construye 1 gráfico (dimensiones) que permitan mostrar de manera simple los insight relevantes encontrados en los datos.	No construye gráficos.	15%
Porcentaje dimensión encargo						30%
Dimensión presentación						
1. Demuestra dominio sobre la construcción del proceso de carga de datos Batch en	Demuestra un dominio completo y profundo sobre la construcción del proceso de carga de datos Batch en diferentes	Demuestra dominio sobre la construcción del proceso de carga de datos Batch en diferentes formatos y de diversas	Demuestra dominio sobre la construcción del proceso de carga de datos Batch en diferentes formatos y de	Demuestra dominio del tema, aunque con errores relevantes sobre la construcción del proceso de carga de datos Batch	No demuestra conocimiento sobre la construcción del proceso de	15%

diferentes formatos y de diversas fuentes, fundamentando con argumentos coherentes y propios de la disciplina.	formatos y de diversas fuentes. Presenta argumentos coherentes, detallados y bien fundamentados, utilizando terminología adecuada y ejemplos relevantes de la disciplina.	fuentes, aunque faltan algunos detalles o ejemplos específicos de la disciplina.	diversas fuentes, pero presenta argumentos superficiales o parcialmente desarrollados, además faltan algunos detalles o ejemplos específicos de la disciplina.	en diferentes formatos y de diversas fuentes. Además, presenta argumentos superficiales o parcialmente desarrollados, y faltan algunos detalles o ejemplos específicos de la disciplina.	carga de datos Batch en diferentes formatos y de diversas fuentes, con uso inadecuado de terminología.	
2. Demuestra dominio sobre el almacenamiento de información para realizar procesos de limpieza y transformación de datos, fundamentando con argumentos coherentes y propios de la disciplina.	Demuestra un dominio completo y profundo sobre el almacenamiento de información para realizar procesos de limpieza y transformación de datos. Presenta argumentos coherentes, detallados y bien fundamentados, utilizando terminología adecuada y ejemplos relevantes de la disciplina.	Demuestra dominio sobre el almacenamiento de información para realizar procesos de limpieza y transformación de datos, aunque faltan algunos detalles o ejemplos específicos de la disciplina.	Demuestra dominio sobre la construcción del proceso de carga de datos en diferentes formatos y de diversas fuentes, pero presenta argumentos superficiales o parcialmente desarrollados, además faltan algunos detalles o ejemplos específicos de la disciplina.	Demuestra dominio del tema, aunque con errores relevantes sobre la construcción del proceso de carga de datos en diferentes formatos y de diversas fuentes, Además, presenta argumentos superficiales o parcialmente desarrollados, y faltan algunos detalles o ejemplos específicos de la disciplina.	No demuestra dominio sobre el almacenamiento o de información para realizar procesos de limpieza y transformación de datos, con uso inadecuado de terminología.	15%
3. Demuestra dominio sobre la construcción de procesos de limpieza, transformación y almacenamiento de grandes volúmenes de datos, fundamentando con argumentos coherentes y propios de la disciplina.	Demuestra un dominio completo y profundo sobre la construcción de procesos de limpieza, transformación y almacenamiento de grandes volúmenes de datos. Presenta argumentos coherentes, detallados y bien fundamentados, utilizando terminología adecuada y ejemplos relevantes de la disciplina.	Demuestra dominio sobre la construcción de procesos de limpieza, transformación y almacenamiento de grandes volúmenes de datos, aunque faltan algunos detalles o ejemplos específicos de la disciplina.	Demuestra dominio sobre la construcción de procesos de limpieza, transformación y almacenamiento de grandes volúmenes de datos, pero presenta argumentos superficiales o parcialmente desarrollados, además faltan algunos detalles o ejemplos específicos de la disciplina.	Demuestra dominio del tema, aunque con errores relevantes sobre la construcción de procesos de limpieza, transformación y almacenamiento de grandes volúmenes de datos. Además, presenta argumentos superficiales o parcialmente desarrollados, y faltan algunos detalles o ejemplos específicos de la disciplina.	No demuestra conocimiento sobre la construcción de procesos con el fin de realizar limpieza, transformación y almacenamiento o de grandes volúmenes de datos, con uso inadecuado de terminología.	15%
4. Demuestra dominio en la construcción de los gráficos que muestran de manera	Demuestra un dominio completo y profundo sobre la construcción de los gráficos que muestran	Demuestra dominio sobre la construcción de los gráficos que muestran de manera simple los insight	Demuestra dominio sobre la construcción de los gráficos que muestran de manera	Demuestra dominio del tema, aunque con errores relevantes sobre la construcción de los	No demuestra conocimiento sobre la construcción de	25%

simple los insight relevantes encontrados en los datos, fundamentando con argumentos coherentes y propios de la disciplina.	de manera simple los insight relevantes encontrados en los datos. Presenta argumentos coherentes, detallados y bien fundamentados, utilizando terminología adecuada y ejemplos relevantes de la disciplina.	relevantes encontrados en los datos, aunque faltan algunos detalles o ejemplos específicos de la disciplina.	simple los insight relevantes encontrados en los datos, pero presenta argumentos superficiales o parcialmente desarrollados, además faltan algunos detalles o ejemplos específicos de la disciplina.	gráficos que muestran de manera simple los insight relevantes encontrados en los datos. Además, presenta argumentos superficiales o parcialmente desarrollados, y faltan algunos detalles o ejemplos específicos de la disciplina.	los gráficos que muestran de manera simple los insight relevantes encontrados en los datos con uso inadecuado de terminología.	
Porcentaje dimensión presentación						70%
Total						100%